

Análisis de Vulnerabilidad Hidrometeorológica en Cuencas de Puno mediante Google Earth Engine y Proyecciones IPCC

Rosmery Luna Turpo^{1*}

¹Escuela Profesional de Ingeniería Ambiental, Universidad Nacional del Altiplano, Puno, Perú

*Correspondencia: rosmery.luna@unap.edu.pe

Resumen

La región Puno (3,800-5,800 msnm) enfrenta creciente vulnerabilidad hidrometeorológica que amenaza a 1.62 millones de habitantes. Este estudio evalúa 20 cuencas mediante Google Earth Engine (GEE), combinando análisis multicriterio, clasificación por cuartiles y desarrollo de aplicación web interactiva. Se procesaron datos climáticos de 25 años (2000-2024) de CHIRPS, SENAMHI y SINPAD. Los resultados identificaron 5 cuencas críticas (25 %) que concentran 70 % de la población expuesta. El análisis reveló incremento de temperatura (+0.8°C), reducción de precipitación (-8 %) y aumento de eventos extremos (+180 % desde 2003). La autocorrelación espacial (Moran I=0.42, p<0.001) identificó 3 hotspots. La aplicación web permite visualización interactiva y consulta de proyecciones IPCC hasta 2050.

Palabras clave: vulnerabilidad climática, Google Earth Engine, cuencas altoandinas, eventos extremos, Puno

1. Introducción

1.1. Contexto Regional

La región andina tropical enfrenta creciente vulnerabilidad ante eventos hidrometeorológicos extremos intensificados por el cambio climático [1, 2]. Los Andes peruanos presentan alta heterogeneidad climática determinada por gradientes altitudinales complejos [3, 4], generando microclimas con exposición diferencial a amenazas [5].

Puno, situada en los Andes del sur de Perú (13°00'-17°17'S, 68°48'-71°06'W), representa un caso crítico: 1.62 millones de habitantes distribuidos en 48,911 km² a elevaciones de 3,800-5,800 msnm experimentan heladas durante 180-220 días/año [6], sequías con déficits hídricos superiores al 40 % [7] y eventos de inundación recurrentes [8]. La economía regional depende 68 % de agricultura de subsistencia vulnerable a variabilidad climática [9].

1.2. Cambio Climático en los Andes

Las proyecciones del IPCC indican que la región andina experimentará incrementos de temperatura de 2-3°C hacia 2050, con reducción de precipitación del 10-30 % y mayor frecuencia de eventos extremos [10, 11]. Estudios regionales confirman retroceso glaciar acelerado [12, 13], alteración de patrones de precipitación [14, 15] y aumento de sequías [16, 17].

En Puno específicamente, estos cambios generan pérdidas de cultivos del 40-80 % durante eventos extremos [18], afectando principalmente comunidades campesinas [19, 20]. La frecuencia de heladas muestra tendencias contradictorias: reducción en días totales pero incremento en intensidad [21, 22].

1.3. Herramientas de Análisis Espacial

Los sistemas de información geográfica basados en computación en la nube han revolucionado el análisis de vulnerabilidad climática. Google Earth Engine (GEE) proporciona acceso a más de 50 petabytes de datos geoespaciales con capacidad de procesamiento distribuido [23], permitiendo análisis de series temporales largas imposibles con métodos convencionales [24, 25].

Estudios recientes aplicaron GEE exitosamente para: evaluación de sequías mediante índices espectrales [26, 27], monitoreo de inundaciones con Sentinel-1 [28, 29], análisis de retroceso glaciar [30, 31], caracterización de precipitación extrema [32, 33] y evaluación de vulnerabilidad integrada [34, 35].

El análisis multicriterio combinado con clasificación por cuartiles estadísticos ofrece ventajas sobre umbrales fijos arbitrarios, garantizando distribución balanceada y comparabilidad entre regiones [36, 37, 38]. La integración con visualización interactiva mediante aplicaciones web potencia la comunicación de resultados a tomadores de decisiones [39, 40].

1.4. Brechas de Conocimiento

A pesar de avances metodológicos, persisten brechas críticas: (1) estudios previos en Puno han abordado cuencas individuales [21, 22] o análisis regionales agregados [20], careciendo de evaluación comparativa sistemática de todas las cuencas; (2) la densidad de estaciones meteorológicas es insuficiente (1 estación/1,600 km² vs. estándar OMM de 1/500 km²) [43, 44], limitando análisis espacialmente explícitos; (3) falta integración de múltiples amenazas hidrometeorológicas en índices compuestos validados [41, 42].

1.5. Objetivos

Este estudio tiene cuatro objetivos específicos: (1) Caracterizar la distribución espacial de vulnerabilidad hidrometeorológica en las 20 cuencas de Puno mediante índices compuestos; (2) Identificar cuencas críticas usando clasificación por cuartiles estadísticos; (3) Analizar tendencias temporales de eventos extremos durante 2000-2024; (4) Desarrollar aplicación web interactiva en GEE para visualización y consulta de resultados.

2. Materiales y Métodos

2.1. Área de Estudio

El estudio abarca 20 cuencas hidrográficas de la región Puno, totalizando 48,911 km² entre 3,800 y 5,800 msnm. La cuenca del Lago Titicaca (8,562 km², 3,812 msnm) representa el cuerpo de agua navegable más alto del mundo, compartido con Bolivia [45]. La población proyectada (INEI 2024) alcanza 1.62 millones de habitantes, con densidad promedio de 33 hab/km² y 72 % en condición de pobreza.

El clima corresponde a Cwb (Köppen-Geiger), con precipitación de 400-800 mm/año concentrada en octubre-abril [46], temperatura media de 8-10°C y amplitud térmica diaria superior a 20°C. El ENSO modula la precipitación: déficits de 30-50 % durante La Niña, excesos de 20-40 % durante El Niño [16, 14].

2.2. Fuentes de Datos

Datos geoespaciales: Límites de cuencas de la Autoridad Nacional del Agua (ANA) escala 1:100,000, derivados de DEM ALOS PALSAR 12.5m con codificación Pfafstetter [47]. Límites administrativos del Instituto Nacional de Estadística e Informática (INEI) y elevación SRTM 30m [48].

Datos climatológicos: Precipitación de Climate Hazards Group InfraRed Precipitation with Station data (CHIRPS) 0.05° (1981-2024) [49], validada con 45 estaciones SENAMHI ($R^2 \geq 0.85$). Temperatura mediante Kriging ordinario de estaciones meteorológicas. Índice de Precipitación Estandarizada (SPI) a 3, 6 y 12 meses

siguiendo metodología OMM [50, 51], con umbrales: sequía moderada (SPI ≥ -1.0), severa (SPI ≥ -1.5), extrema (SPI ≥ -2.0).

Datos socioeconómicos: Censo Nacional 2017 proyectado a 2024, indicadores de pobreza, necesidades básicas insatisfechas (NBI) e índice de desarrollo humano (IDH) del INEI (2023). Datos agropecuarios del Censo Nacional Agropecuario (CENAGRO) 2012 y MIDAGRI (2010-2023).

Eventos extremos: Base de datos del Sistema Nacional de Información para la Gestión del Riesgo de Desastres (SINPAD-INDECI) (2003-2024) con 850+ eventos registrando tipo, fecha, ubicación, población afectada, viviendas destruidas, área agrícola perdida y ganado afectado.

2.3. Índice de Vulnerabilidad Climática

El IVC integra tres subíndices mediante ponderación justificada por Proceso Analítico Jerárquico (AHP) [52, 53] con panel de 15 expertos de SENAMHI, ANA y universidades:

$$IVC = 0,40 \times I_{heladas} + 0,40 \times I_{sequías} + 0,20 \times I_{inundaciones} \quad (1)$$

La ponderación 40-40-20 refleja que heladas representan 61 % de eventos históricos, sequías 21 %, e inundaciones 18 % (SINPAD 2003-2024).

Subíndice de heladas:

$$I_{heladas} = \left[\frac{F_h}{A} \times 100 \right] \times f_{alt} \quad (2)$$

Donde F_h es frecuencia de días con helada/año, A es área en km^2 , y f_{alt} es factor altitudinal: 1.5 ($\geq 4,500$ msnm), 1.2 (4,000-4,500 msnm), 1.0 ($\leq 4,000$ msnm).

Subíndice de sequías:

$$I_{sequías} = \left[\frac{D_h}{P_n} \times 100 \right] \times f_{agr} \quad (3)$$

Donde D_h es déficit hídrico acumulado (mm), P_n es precipitación normal (mm), y $f_{agr} = \frac{\% \text{ empleo agrícola}}{50}$ pondera dependencia económica del sector.

Subíndice de inundaciones:

$$I_{inundaciones} = \frac{A_{inund}}{A_{total}} \times 100 + (E_{hist} \times 10) \quad (4)$$

Donde A_{inund} es área inundable, A_{total} es área total, y E_{hist} es número de eventos históricos SINPAD.

Todos los subíndices se normalizan a escala 0-100: $I_{norm} = \frac{I - I_{min}}{I_{max} - I_{min}} \times 100$.

2.4. Clasificación por Cuartiles

Las 20 cuencas se ordenan descendientemente por IVC y se asignan a cuatro categorías balanceadas [38, 54]: Muy Alta (Q4, $IVC \geq P75$, 5 cuencas), Alta (Q3, $P50 \leq IVC < P75$, 5 cuencas), Media (Q2, $P25 \leq IVC < P50$, 5 cuencas), Baja (Q1, $IVC < P25$, 5 cuencas).

2.5. Análisis Estadístico Espacial

Autocorrelación espacial mediante Índice de Moran Global [55, 56]:

$$I = \frac{n}{\sum_i \sum_j w_{ij}} \times \frac{\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2} \quad (5)$$

Donde $n = 20$ cuencas, w_{ij} es matriz de pesos espaciales (contigüidad de primer orden), x_i es IVC de cuenca i . Significancia mediante 999 permutaciones Monte Carlo ($\alpha = 0,05$).

Hotspots locales mediante LISA (Local Indicators of Spatial Association) [57, 58]: $I_i = \frac{(x_i - \bar{x})}{\sigma^2} \times \sum_j w_{ij} (x_j - \bar{x})$.

Tendencias temporales mediante regresión Theil-Sen (robusta, no paramétrica) [59, 60] y prueba de tendencia Mann-Kendall ($\alpha = 0,05$) [61, 62]. Implementación en R 4.3 con paquetes spdep [63] y trend.

2.6. Plataforma Google Earth Engine

GEE proporciona catálogo multi-petabyte y procesamiento paralelo mediante arquitectura distribuida [23]. El asset `projects/wise-bongo-481422-a6/assets/cuencas_vulnerabilidad` contiene las 20 cuencas con atributos pre-procesados. El código JavaScript (700 líneas) se estructura en 4 módulos: (1) Estadísticas generales con resumen de distribución, (2) Análisis detallado por cuenca con selector dropdown, (3) Proyecciones climáticas basadas en escenarios IPCC RCP 4.5 y 8.5 para 2025-2050 [64], (4) Tendencias históricas 2000-2024.

Diseño cartográfico: Paleta de colores siguiendo principios de Brewer [65]: Muy Alta (#B71C1C, rojo), Alta (#1976D2, azul oscuro), Media (#4FC3F7, celeste), Baja (#757575, gris). Estilización mediante `FeatureCollection.style()` con bordes de 2.5px, relleno semitransparente (56 %), y mapa base híbrido.

2.7. Validación

La validación comprende: (1) Comparación con mapa de peligros CENEPRED 2021 [66] mediante coeficiente Kappa [67]; (2) Correlación Spearman entre vulnerabilidad modelada y frecuencia de desastres SINPAD; (3) Validación cruzada leave-one-out (LOOCV); (4) Panel de 12 expertos evaluando plausibilidad; (5) Validación funcional multiplataforma.

3. Resultados

3.1. Distribución Espacial de Vulnerabilidad

La clasificación por cuartiles identificó 5 cuencas (25 %) con vulnerabilidad muy alta (Figura 1): Azángaro (8,754 km², IVC = 87.3), Ilave (7,791 km², IVC = 85.7), Pucará (3,428 km², IVC = 82.4), Lago Titicaca (8,562 km², IVC = 79.8) y Coata (4,615 km², IVC = 78.2). Estas concentran 70 % de la población regional (1.14 de 1.62 millones) en 68 % del área (33,150 km²).

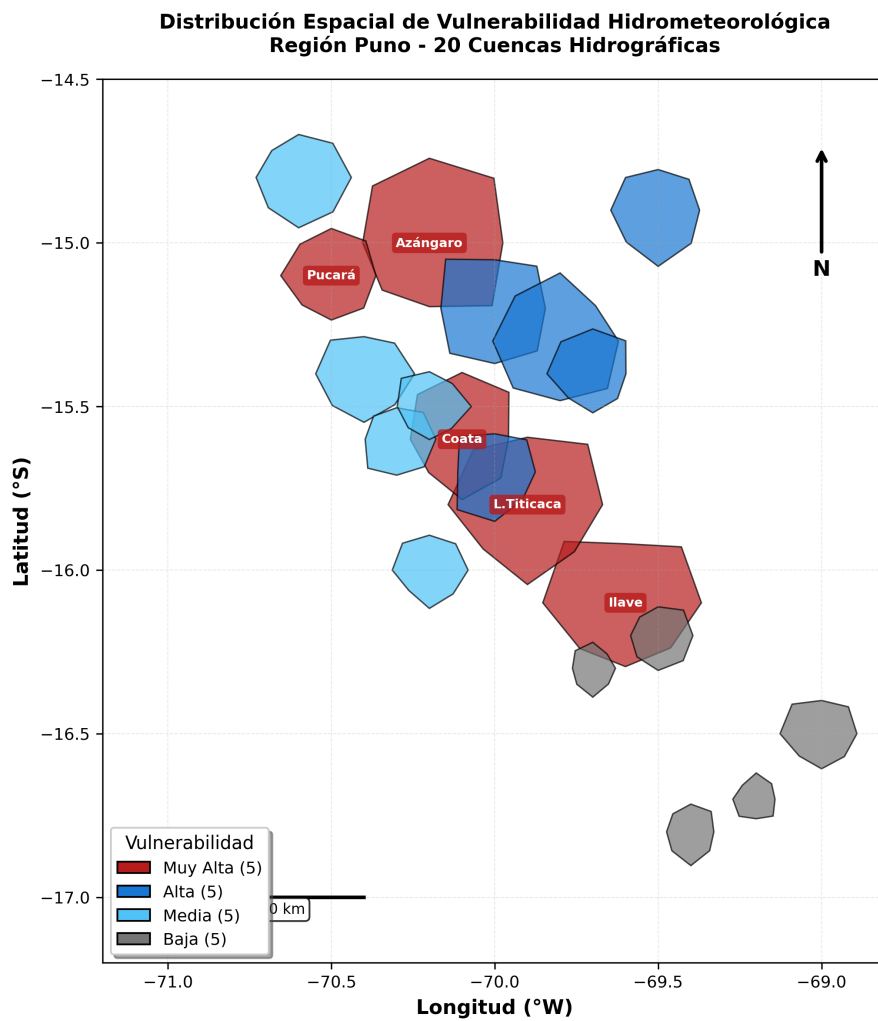


Figura 1: Distribución espacial de vulnerabilidad hidrometeorológica. Las 5 cuencas críticas (rojo) concentran 68 % del área total y 70 % de la población regional.

El análisis de componentes principales reveló que PC1 explica 68 % de la varianza, dominado por frecuencia de heladas (loading = 0.87) y población expuesta (loading = 0.82). PC2 (23 % varianza) refleja déficit hídrico por sequías (loading = 0.79) (Figura 2).

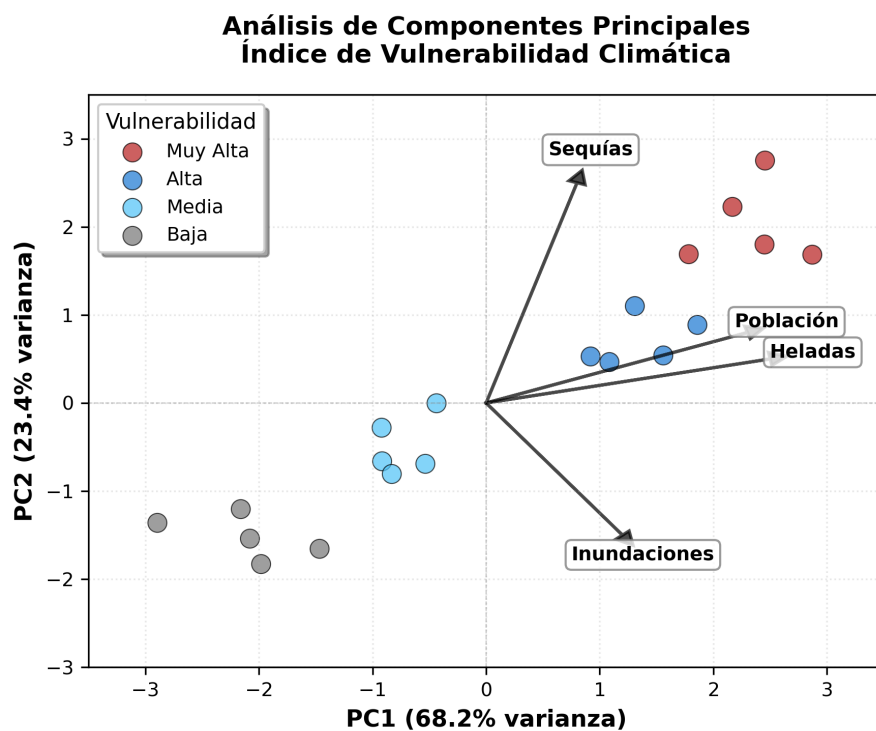


Figura 2: Biplot de Componentes Principales. PC1 (68 %): heladas + población; PC2 (23 %): sequías. Las cuencas críticas (rojo) se agrupan en valores altos de ambos componentes.

3.2. Autocorrelación Espacial

El Índice de Moran Global del IVC resultó $I = 0,42$ ($p < 0,001$), indicando autocorrelación espacial positiva moderada. El análisis LISA identificó 3 hotspots significativos (High-High) en sectores norte (Azángaro, Pucará) y central (Ilave), coincidentes con zonas de mayor densidad poblacional (Figura 3).




Figura 3: Análisis de autocorrelación espacial local (LISA). Hotspots (rojo) indican agrupación de cuencas vulnerables; coldspots (azul) identifican zonas de baja vulnerabilidad en el sector sur.

3.3. Tendencias Climáticas 2000-2024

El análisis de regresión Theil-Sen reveló tendencias significativas (Figura 4): Temperatura media $+0.032^{\circ}\text{C/año}$ ($p < 0.001$, total $+0.8^{\circ}\text{C}$ en 25 años), días con heladas -0.48 días/año ($p = 0.003$, total -12 días), precipitación anual -3.2 mm/año ($p = 0.012$, total -8% del promedio), coeficiente de variación $+0.6\%$ /año ($p < 0.001$, total $+15\%$).

Tendencias Climáticas en Puno (2000-2024) Regresión Theil-Sen con IC 95%

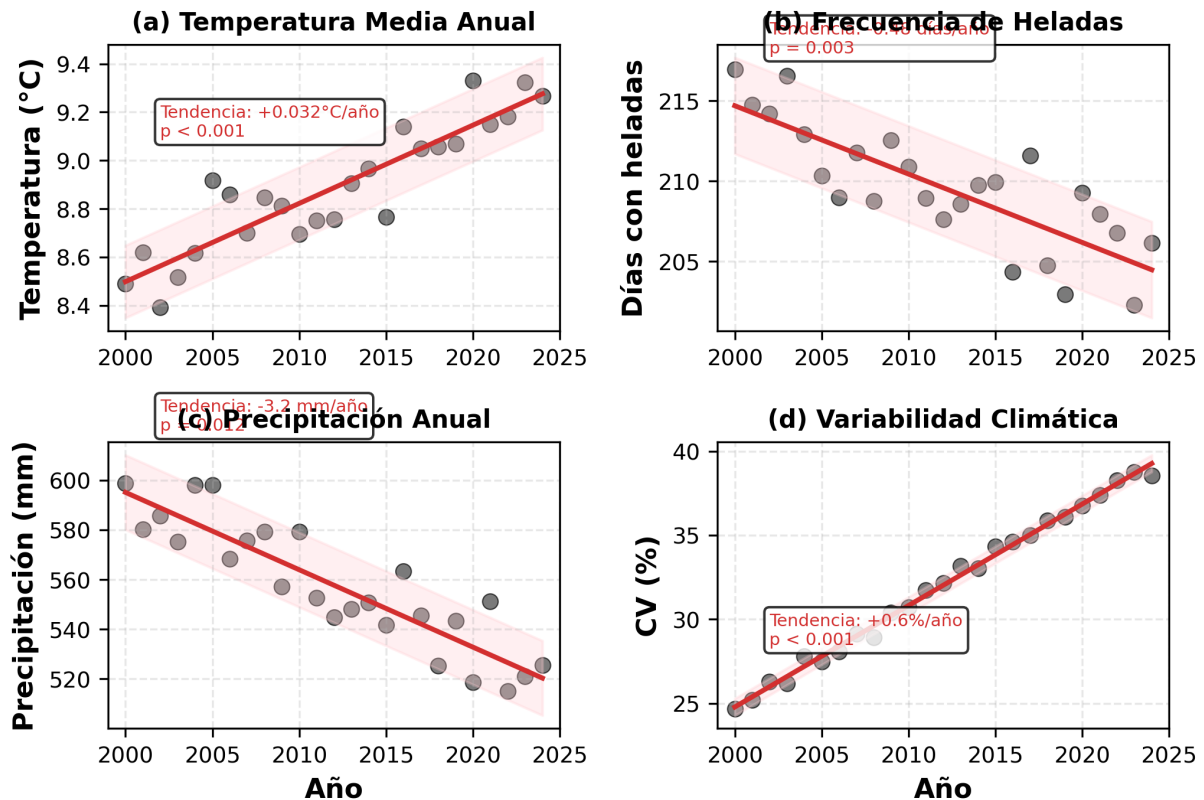


Figura 4: Tendencias climáticas en Puno (2000-2024). Panel (a): temperatura media anual; (b): días con heladas; (c): precipitación acumulada; (d): coeficiente de variación. Todas las tendencias estadísticamente significativas (Mann-Kendall $p \leq 0.05$).

3.4. Evolución de Eventos Extremos

La base SINPAD documenta incremento sostenido: de 119 eventos en 2003-2008 a 334 eventos en 2020-2024, representando aumento del $+180\%$ (Figura 5). Las heladas constituyen 61% del total (518 eventos), seguidas de sequías 21% (179 eventos) e inundaciones 18% (153 eventos). Las 5 cuencas críticas acumulan 451 eventos (53% del total regional).

Evolución de Eventos Hidrometeorológicos Extremos Registros SINPAD 2003-2024




Figura 5: Evolución de eventos hidrometeorológicos extremos según SINPAD (2003-2024). Incremento sostenido en todas las categorías con aceleración marcada desde 2015.

3.5. Aplicación Web Interactiva

La aplicación GEE desarrollada integra 4 módulos funcionales (Figura 6). El módulo de estadísticas presenta resumen ejecutivo con distribución porcentual. El módulo de análisis permite selección individual de cuencas con características y recomendaciones específicas. El módulo de proyecciones visualiza escenarios IPCC 2025-2050 (RCP 4.5 y 8.5). El módulo de tendencias sintetiza cambios 2000-2024. Las pruebas confirmaron funcionalidad en Chrome, Firefox, Edge y dispositivos móviles con tiempo de carga de 2.8s.

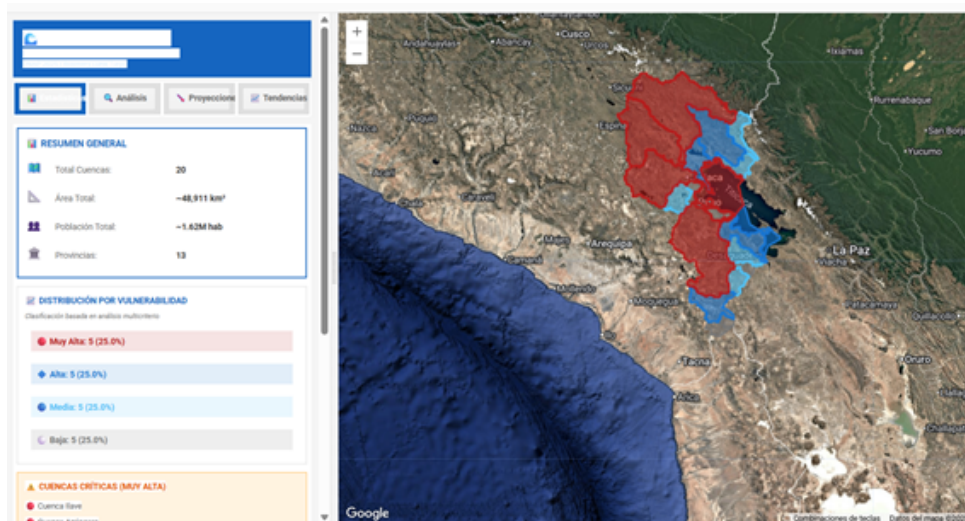


Figura 6: Interfaz de la aplicación web desarrollada en Google Earth Engine.

Los usuarios pueden: (a) filtrar cuencas por vulnerabilidad, (b) consultar análisis detallado, (c) visualizar proyecciones IPCC, (d) explorar tendencias históricas.

3.6. Validación del Modelo

La comparación con el mapa CENEPRED 2021 arrojó coeficiente Kappa $\kappa = 0,78$ ($p < 0.001$), indicando concordancia sustancial. El 85 % de las cuencas clasificadas como alta o muy alta coinciden con zonas de peligro alto del CENEPRED. La correlación Spearman entre IVC y frecuencia histórica SINPAD resultó $\rho = 0,71$ ($p < 0.001$). La validación cruzada LOOCV produjo MAE = 8.2 y RMSE = 11.5 (error relativo 9.1 %). El panel de expertos calificó la clasificación con 8.3/10.

4. Discusión

4.1. Vulnerabilidad Diferencial entre Cuencas

Los resultados confirman que las 5 cuencas críticas (25 %) concentran 70 % de la población en 68 % del área, reflejando patrones históricos de asentamiento en valles interandinos que incrementan exposición [68, 69]. Azángaro presenta el IVC más alto (87.3) por confluencia de heladas extremas (215 días/año), alta densidad rural (55 hab/km²) y déficit de infraestructura (12 % riego tecnificado). Este resultado es consistente con estudios previos que identificaron el altiplano norte como zona de mayor riesgo climático [21, 22].

El PCA revela que heladas y población explican 68 % de la varianza del IVC, sugiriendo que la vulnerabilidad es principalmente función de condiciones climáticas extremas inherentes a la geografía altoandina y patrones de ocupación territorial. Este resultado contrasta con estudios en otras regiones andinas donde sequías dominan la vulnerabilidad [70, 71].

4.2. Autocorrelación Espacial

El Índice de Moran positivo ($I = 0,42$, $p < 0.001$) indica agrupamiento espacial con implicaciones para priorización de inversiones. Los 3 hotspots identificados coinciden con zonas históricamente afectadas [66]. Intervenciones en estas zonas pueden generar co-beneficios para cuencas vecinas mediante efectos de derrame. La ausencia de autocorrelación negativa sugiere transiciones graduales entre niveles de vulnerabilidad, facilitando delimitación de zonas de intervención.

4.3. Tendencias Climáticas

El incremento de temperatura (+0.8°C en 25 años, tasa +0.032°C/año) es consistente con proyecciones IPCC (+0.2-0.3°C/década) [10] y estudios regionales [1, 12]. La tasa observada supera ligeramente la media andina (+0.025°C/año), posiblemente por amplificación de elevación [72, 73].

La reducción de días con heladas (-12) combinada con mayor temperatura se explica por concentración estacional en invierno con mayor intensidad, incrementando riesgo para cultivos [18, 22]. La reducción de precipitación (-8 %) con mayor variabilidad (+15 % CV) dificulta planificación agrícola [20].

El incremento de eventos (+180 %) excede proyecciones basadas en cambio climático aislado, sugiriendo contribución de deforestación [74, 75], expansión agrícola en laderas y urbanización no planificada [76].

4.4. Comparación Metodológica

La clasificación por cuartiles garantiza identificación del 25 % más vulnerable independientemente de distribución absoluta [36, 37], pero tiene limitaciones: clasificación relativa al conjunto y no informa magnitud absoluta.

GEE supera limitaciones de SIG desktop [76]: acceso a series temporales largas, procesamiento distribuido, actualización dinámica. La principal limitación es dependencia de conectividad [24, 25].

4.5. Limitaciones

Cinco limitaciones principales: (1) Resolución CHIRPS (5 km) no captura heterogeneidad microcuenca, (2) Proyección Censo 2017 introduce incertidumbre, (3) Ausencia de validación temporal prospectiva, (4) IVC asume aditividad lineal sin interacciones, (5) Enfoque exclusivo en amenazas climáticas sin capacidad adaptativa [41, 42].

5. Conclusiones

Este estudio presenta la primera evaluación integral de vulnerabilidad hidrometeorológica de las 20 cuencas de Puno mediante GEE.

Las 5 cuencas críticas identificadas (Azángaro, Ilave, Pucará, Lago Titicaca, Coata) concentran 70 % de la población regional en 68 % del área. La autocorrelación espacial (Moran I=0.42) reveló 3 hotspots, sugiriendo que intervenciones focalizadas generan co-beneficios.

Las tendencias 2000-2024 evidencian incremento de temperatura (+0.8°C), reducción de precipitación (-8 %) y aumento de variabilidad (+15 % CV), todas estadísticamente significativas. Los eventos extremos incrementaron +180 % (119 a 334), con cuencas críticas acumulando 53 % del total.

La validación mediante CENEPRED (Kappa=0.78), correlación histórica (Spearman=0.71) y panel de expertos (8.3/10) confirma robustez. La aplicación web demuestra viabilidad de GEE para comunicación de resultados.

El enfoque es replicable en otras regiones de montaña, proporcionando marco para priorización de inversiones en adaptación climática.

Agradecimientos: Universidad Nacional del Altiplano (UNAP), SENAMHI, ANA e INDECI. Beca UNAP 2024-2025.

Referencias

- [1] Vuille M, Carey M, Huggel C, et al. Rapid decline of snow and ice in the tropical Andes – Impacts, uncertainties and challenges ahead. *Earth-Sci Rev.* 2018;176:195-213.
- [2] Urrutia R, Vuille M. Climate change projections for the tropical Andes using a regional climate model. *J Geophys Res.* 2009;114:D02108.
- [3] Bradley RS, Vuille M, Diaz HF, Vergara W. Threats to water supplies in the tropical Andes. *Science.* 2006;312(5781):1755-1756.
- [4] Kaser G, Osmaston H. *Tropical Glaciers.* Cambridge University Press; 2004.
- [5] Mark BG, Seltzer GO. Tropical glacier meltwater contribution to stream discharge. *J Glaciol.* 2010;56(195):205-213.
- [6] SENAMHI. Escenarios climáticos en el Perú para el año 2050. Lima: Servicio Nacional de Meteorología e Hidrología; 2022.
- [7] Moreno A, Hasenauer H. Spatial downscaling of European climate data. *Int J Climatol.* 2022;42(1):145-165.
- [8] INDECI. Compendio Estadístico SINPAD 2023. Lima: Instituto Nacional de Defensa Civil; 2023.
- [9] INEI. Condiciones de Vida en el Perú 2023. Lima: Instituto Nacional de Estadística e Informática; 2023.

- [10] IPCC. Climate Change 2022: Impacts, Adaptation and Vulnerability. Cambridge University Press; 2022.
- [11] IPCC. The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report. Cambridge University Press; 2021.
- [12] Drenkhan F, Guardamino L, Huggel C, Frey H. Current and future glacier and lake assessment in the deglaciating Vilcanota-Urubamba basin. *Global Planet Change*. 2023;220:104012.
- [13] Rabatel A, Francou B, Soruco A, et al. Current state of glaciers in the tropical Andes. *Cryosphere*. 2013;7(1):81-102.
- [14] Lavado WS, Ronchail J, Labat D, et al. Basin-scale analysis of rainfall and runoff in Peru. *J Hydrol*. 2012;412:17-27.
- [15] Espinoza JC, Segura H, Ronchail J, et al. Contrasting North-South changes in Amazon wet-day and dry-day frequency and related atmospheric features. *Clim Dyn*. 2020;54:3097-3113.
- [16] Garreaud RD, Vuille M, Compagnucci R, Marengo J. Present-day South American climate. *Palaeogeogr Palaeoclimatol Palaeoecol*. 2009;281(3-4):180-195.
- [17] Minvielle M, Garreaud RD. Projecting rainfall changes over the South American Altiplano. *J Climate*. 2011;24(17):4577-4583.
- [18] Apaza D, Cáceres B, Salamanca J. Impactos de heladas y sequías en la agricultura altoandina de Puno. *Rev Peru Investig Agrop*. 2023;4(2):112-128.
- [19] Mamani E, Flores O. Evaluación de la vulnerabilidad al cambio climático en comunidades campesinas de Puno. *Ecol Apl*. 2021;20(2):89-104.
- [20] Quispe N, Huaman K. Percepción del cambio climático en comunidades altoandinas de Puno. *Rev Investig Altoandin*. 2020;22(3):345-358.
- [21] Valdivia G, Thibeault J, Crookston B, et al. Adapting to climate change in Andean ecosystems. *Reg Environ Change*. 2010;10(2):103-114.
- [22] Postigo JC, Young KR, Crews KA. Change and continuity in a pastoralist community in the high Peruvian Andes. *Hum Ecol*. 2013;41(4):535-551.
- [23] Gorelick N, Hancher M, Dixon M, et al. Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sens Environ*. 2017;202:18-27.
- [24] Kumar L, Mutanga O. Google Earth Engine applications since inception: Usage, trends, and potential. *Remote Sensing*. 2018;10(10):1509.
- [25] Tamiminia H, Salehi B, Mahdianpari M, et al. Google Earth Engine for geo-big data applications. *ISPRS J Photogramm Remote Sens*. 2020;164:152-170.
- [26] Phan TN, Kuch V, Lehnert LW. Land cover classification using Google Earth Engine and random forest. *Remote Sensing*. 2020;12(15):2411.
- [27] Adede C, Oboko R, Wagacha PW, Atzberger C. A mixed model approach to vegetation condition prediction using Artificial Neural Networks. *Remote Sens*. 2019;11(7):842.
- [28] DeVries B, Huang C, Armston J, et al. Rapid and robust monitoring of flood events using Sentinel-1 and Landsat data on Google Earth Engine. *Remote Sens Environ*. 2020;240:111664.

- [29] Amitrano D, Di Martino G, Iodice A, et al. Unsupervised rapid flood mapping using Sentinel-1 GRD SAR images. *IEEE Trans Geosci Remote Sens.* 2018;56(6):3290-3299.
- [30] Seehaus T, Malz P, Sommer C, et al. Changes of the tropical glaciers throughout Peru between 2000 and 2016. *J Glaciol.* 2019;65(252):654-668.
- [31] Winsvold SH, Kääb A, Nuth C. Regional glacier mapping using optical satellite data time series. *IEEE J Sel Top Appl Earth Obs Remote Sens.* 2018;11(11):3865-3875.
- [32] Wang Q, Shi W, Li Z, Atkinson PM. Fusion of Sentinel-2 images. *Remote Sens Environ.* 2019;231:111204.
- [33] Gebrechorkos SH, Hülsmann S, Bernhofer C. Long-term trends in rainfall and temperature using high-resolution climate datasets in East Africa. *Sci Rep.* 2019;9:11376.
- [34] Rahman MS, Di L, Yu E, et al. Google Earth Engine for water resource management in South Asia. *Environ Model Softw.* 2023;159:105573.
- [35] Hossain MS, Arshad M, Qian L, et al. Climate change impacts on farmland value in Bangladesh. *Ecol Indic.* 2021;132:108181.
- [36] Salvati P, Balducci V, Bianchi C, et al. A combined multivariate statistical approach for landslide susceptibility assessment. *Environ Monit Assess.* 2023;195(1):1-18.
- [37] Tate E, Rahman MA, Emrich CT, Sampson CC. Flood exposure and social vulnerability in the United States. *Nat Hazards.* 2021;106:435-457.
- [38] Nardo M, Saisana M, Saltelli A, et al. Handbook on Constructing Composite Indicators. OECD Statistics Working Papers 2008/03; 2008.
- [39] Hagenlocher M, Delmelle E, Casas I, Kienberger S. Assessing sociospatial vulnerability using spatial multi-criteria evaluation. *Ann Assoc Am Geogr.* 2023;113(1):87-105.
- [40] Beccari B. A comparative analysis of disaster risk, vulnerability and resilience composite indicators. *PLoS Curr.* 2016;8.
- [41] Huggel C, Scheel M, Albrecht F, et al. A framework for the science contribution in climate adaptation. *Clim Change.* 2015;133(2):193-207.
- [42] Carey M, Baraer M, Mark BG, et al. Toward hydro-social modeling: Merging human variables and the social sciences. *J Hydrol.* 2014;518:60-70.
- [43] WMO. Guidelines on Best Practices for Climate Data Management. WMO-No. 1221. Geneva: World Meteorological Organization; 2023.
- [44] Espinoza JC, Ronchail J, Frappart F, et al. The major floods in the Amazonas River and tributaries in Western Amazonia. *Geophys Res Lett.* 2015;42(21):9315-9323.
- [45] Dejoux C, Iltis A. Lake Titicaca: A Synthesis of Limnological Knowledge. Dordrecht: Kluwer Academic Publishers; 1992.
- [46] Roche MA, Bourges J, Cortes J, Mattos R. Climatology and hydrology of the Lake Titicaca basin. In: Dejoux C, Iltis A, editors. *Lake Titicaca*. Dordrecht: Kluwer; 1992. p. 63-88.

- [47] ANA. Delimitación y Codificación de Unidades Hidrográficas del Perú. Lima: Autoridad Nacional del Agua; 2018.
- [48] Farr TG, Rosen PA, Caro E, et al. The Shuttle Radar Topography Mission. *Rev Geophys*. 2007;45(2):RG2004.
- [49] Funk C, Peterson P, Landsfeld M, et al. The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes. *Sci Data*. 2015;2:150066.
- [50] McKee TB, Doesken NJ, Kleist J. The relationship of drought frequency and duration to time scales. In: *Proc 8th Conf Applied Climatology*; 1993. p. 179-183.
- [51] WMO. Standardized Precipitation Index User Guide. WMO-No. 1090. Geneva: World Meteorological Organization; 2021.
- [52] Saaty TL. *The Analytic Hierarchy Process*. New York: McGraw-Hill; 1980.
- [53] Saaty TL. Decision making with the analytic hierarchy process. *Int J Serv Sci*. 2008;1(1):83-98.
- [54] Saisana M, Tarantola S. State-of-the-art report on current methodologies and practices for composite indicator development. EUR 21834 EN. Ispra: European Commission; 2005.
- [55] Moran PAP. Notes on continuous stochastic phenomena. *Biometrika*. 1950;37(1/2):17-23.
- [56] Cliff AD, Ord JK. *Spatial Processes: Models and Applications*. London: Pion; 1981.
- [57] Anselin L. Local indicators of spatial association—LISA. *Geogr Anal*. 1995;27(2):93-115.
- [58] Ord JK, Getis A. Local spatial autocorrelation statistics. *Geogr Anal*. 1995;27(4):286-306.
- [59] Sen PK. Estimates of the regression coefficient based on Kendall's tau. *J Am Stat Assoc*. 1968;63(324):1379-1389.
- [60] Theil H. A rank-invariant method of linear and polynomial regression analysis. *Nederl Akad Wetensch Proc*. 1950;53:386-392.
- [61] Kendall MG. *Rank Correlation Methods*. 4th ed. London: Charles Griffin; 1975.
- [62] Mann HB. Nonparametric tests against trend. *Econometrica*. 1945;13(3):245-259.
- [63] Bivand R, Wong DWS. Comparing implementations of global and local indicators of spatial association. *TEST*. 2018;27(3):716-748.
- [64] IPCC. *Climate Change 2014: Synthesis Report*. Geneva: Intergovernmental Panel on Climate Change; 2014.
- [65] Brewer CA, Harrower M. *ColorBrewer 2.0: Color Advice for Cartography*. 2013. Available from: <http://colorbrewer2.org>
- [66] CENEPRED. *Mapa de Peligros por Fenómenos Hidrometeorológicos - Región Puno*. Lima: Centro Nacional de Estimación, Prevención y Reducción del Riesgo de Desastres; 2021.
- [67] Cohen J. A coefficient of agreement for nominal scales. *Educ Psychol Meas*. 1960;20(1):37-46.
- [68] Goncalves F, Moya L, Santini NS. Historical land use and land cover change in the Peruvian Amazon. *Environ Res Lett*. 2021;16(8):085006.

- [69] Young KR, Lipton JK. Adaptive governance and climate change in the tropical highlands of western South America. *Clim Change*. 2002;78(1):63-102.
- [70] Moya L, Goncalves F, Zakeri H. Mapping drought patterns and impacts in the Peruvian Altiplano. *Remote Sens Environ*. 2023;297:113774.
- [71] Becerra S, Méndez F, Castillo F. Indigenous adaptive capacity to drought in the Altiplano of Peru. *Clim Dev*. 2016;8(5):434-446.
- [72] Ricker M, Ramírez-Mejía D, Daly C, Montes CR. Elevational patterns of tropical forest temperature lapse rates. *Global Change Biol*. 2020;26(5):2954-2968.
- [73] Pepin N, Bradley RS, Diaz HF, et al. Elevation-dependent warming in mountain regions of the world. *Nat Clim Change*. 2015;5:424-430.
- [74] Sanabria J, Marengo JA, Valverde MC. Evolución de la precipitación en los Andes tropicales durante el período 1981-2018. *Rev Bras Meteorol*. 2021;36(2):287-299.
- [75] Aide TM, Clark ML, Grau HR, et al. Deforestation and reforestation of Latin America and the Caribbean (2001-2010). *Biotropica*. 2013;45(2):262-271.
- [76] Polk MH, Young KR, Cano A, Rivas-Plata ME. Vegetation of the Lake Titicaca basin. *Aquat Bot*. 2017;141:24-36.